

Prediktera maskinfel inom industrin

Projekt i Data Science



Jakob Rask
EC Utbildning
Rapport
202411

Abstract

The project is a team collaboration to develop an End-to-End project, from data collection and data transformation to EDA and Machine Learning and finally deployment as a Streamlit application.

The aim for this project is to investigate how machine learning can be used to predict machine failures.

By predicting RUL (Remaining Useful Life) for machines companies can perform predictive maintenance, to save time and money compared to traditional preventive maintenance.

The predictions show different results on different machines. The predictions work well for some machines, but worse for others.

The visualizations in the app enables the user to follow the predictions accuracy versus the actual values.

Innehållsförteckning

1	Inledning.....	1
1.1	Syfte	1
1.2	Frågeställning.....	1
2	Teori.....	2
2.1	Tidsserier och RUL (Remaining Useful Life)	2
2.2	Modeller.....	2
2.3	Streamlit.....	2
3	Metod	3
3.1	Arbetsmetod	3
3.2	Modellen	3
3.2.1	Utforska och förstå inhämtade data.....	3
3.2.2	Val av modeller	4
3.3	Streamlit-appen	5
4	Resultat och Diskussion.....	6
4.1	Modellerna.....	6
4.2	Streamlit-applikationen	7
5	Slutsatser	8
5.1	Vidare arbete	8
6	Självutvärdering.....	9
	Källförteckning.....	10

1 Inledning

Traditionellt sett har preventivt underhåll använts inom industrin, att vid regelbundna tillfällen byta ut eller reparera maskinerdelar för att undvika ett produktionsstopp. Detta tar då inte hänsyn till komponentens eller maskinens egentliga tillstånd. Om maskindelarna egentligen kan klara sig längre så blir detta en onödigt kostsam metod.

Prediktivt underhåll används idag mer och mer för att i stället utföra reparation eller utbyte i rätt tid innan ett maskinfel antas uppstå. Denna metod kan då spara företagen både tid och pengar (Wikipedia, 2024).

Projektet utförs som grupparbete från början till slut, med datainsamling, databearbetning, dataanalys och maskininlärning och slutligen en app för slutanvändare.

Den data som används är hämtad från Kaggle (<https://www.kaggle.com/datasets/arnabbiswas1/microsoft-azure-predictive-maintenance>) och består av fem olika dataset, som csv-filer. De ger tillsammans information kring 100 maskiners sensordata, ålder, maskintyp, tidpunkt då felmeddelande, maskinfel och underhåll inträffat under ett års tid.

1.1 Syfte

Syftet är att skapa modeller för prediktivt underhåll med hjälp av den data som finns tillgänglig. Genom att prediktera RUL (Remaining Useful Life), dvs återstående tid som maskinen är i dugligt skick, är målet att kunna ge en grund till prediktivt underhåll.

1.2 Frågeställning

- Klarar modellen av att prediktera RUL för maskinerna tillräckligt bra?
- Hur bra är modellen på att prediktera sensordata?

2 Teori


2.1 Tidsserier och RUL (Remaining Useful Life)

De aktuella dataseten är i form av tidsserier, närmare bestämt multivariata tidsserier. Det innebär att data är en sekvens av flera värden per tidssteg (Géron, 2019, s.503). I detta fall finns data för olika sensorer (volt, rotation, tryck och vibration) uppmätt varje heltimme under ett års tid.

RUL (Remaining Useful Life) är den tid som återstår innan en komponent eller maskin behöver repareras eller bytas ut (Stratada, 2024). RUL kan ses som en typ av prognos för när ett fel kan komma att inträffa. Att prediktera RUL är en viktig del när det gäller prediktivt underhåll. Genom att prediktera RUL kan reparationer utföras i rätt tid, vilket kan minska onödigt många rutinmässigt utförda reparationer samt minska risken för maskinstopp, vilket kan bespara företagen mycket pengar.

2.2 Modeller

För att modellera tidsseriedata har vi använt oss av RNN-modeller, med lager såsom LSTM och GRU. En RNN-modell är en neural nätverksmodell för djupinlärning som kan hantera tidsseriedata som input och output. För varje tidssteg mottager varje neuron både en input-vektor och output-vektorn från föregående tidssteg (Géron, 2019, s.498).



Figur 1. Ett RNN-lager (till vänster) som rullas ut genom tidsstegen (till höger) (Géron, 2019, p.499).

För att förbättra modeller som hanterar längre sekvenser används vanligtvis LSTM (Long Short-Term Memory) eller GRU (Gated Recurrent Unit). GRU är en förenklad variant av LSTM, men de fungerar ungefär lika bra (Géron, 2019, s.519).

2.3 Streamlit

Streamlit är ett ramverk som gör det enklare att skapa applikationer för maskininlärning, då det inte kräver kunskaper om att bygga web-applikationer (Streamlit, 2024).

3 Metod

3.1 Arbetsmetod

Detta projekt är genomfört som ett grupparbete om tre personer. Den arbetsmetod som gruppen använt är inspirerad av Scrum-metoden. Scrum är en agil arbetsmetod som bygger på så kallade "sprints", där gruppen gör bestämda uppgifter och arbetar mot ett gemensamt mål (Schwaber, K. & Sutherland, J., 2020). Gruppen hade dagliga avstämningar och uppföljningar kring hur arbetet gått.

För att hålla koll på tidsåtgång och alla moment som skall utföras och vem eller vilka som ansvarade för vad så skapades ett "Scrum-board". Det gav en tydlig överblick över vad som ska göras, när och i vilken ordning. De flesta moment utfördes gemensamt med dagliga avstämningar.


En gemensam GitHub-repository har använts under projektets gång som plattform och för versionshantering.

3.2 Modellen

Då tidsseriesdata behöver vara i kronologisk ordning kan vi inte göra en randomiserad "train-test-split". I stället görs en split där träningsdata utgörs av de 8 första månaderna, valideringsdata nästföljande 2 månader och testdata de sista 2 månaderna.


3.2.1 Utforska och förstå inhämtade data

I de genomförda dataanalyserna framkommer att sensordata fluktuerar inom ett visst intervall, utan något uppenbart samband, se Figur 2 nedan.



Figur 2. Exempel på hur sensordata ser ut för en maskin, i detta fall "rotation" för maskin nr 1.


Som Figur 3 visar är sensorvärdena även normalfördelade över tid.



Figur 3. Histogram över fördelningen av värdena för "rotation" avseende maskin nr 1.

I analyserna framkommer även ett tydligt mönster gällande underhållet av maskinerna. Underhåll sker regelbundet med ett visst tidsintervall för respektive maskin, se Figur 4 nedan.

En del av reparationerna sammanfaller med maskinfel men merparten är regelbundna tillfällen då underhåll har utförts på respektive maskin.



Figur 4. Fördelningen av reparationer över tid för alla maskiner.

3.2.2 Val av modeller

Då modellerna ska hantera tidsseriedata föll valet på LSTM- och GRU-modeller som båda lämpar sig väl för den typen av data. Både LSTM- och GRU-modeller har prövats med olika lageruppbyggnader och hyperparameterinställningar för att hitta det som verkar fungera bäst. För RUL-prediktering valdes en LSTM-modell och för prediktering av sensordata valdes en GRU-modell.


Varje modell har tränats på träningsdata (de 8 första månaderna) och utvärderats på valideringsdata (nästföljande 2 månader).

Efter att den bästa modellen för ändamålet valts ut tränas modellen om på utökade träningsdata (inklusive valideringsdata). Denna tränade modell används slutligen för att utföra prediktioner på testdata (de sista 2 månaderna i tidsserien), vilket görs i Streamlit-applikationen.

3.3 Streamlit-appen

För att kunna visa det vi vill i appen, och få det att fungera så smidigt möjligt, behöver vi ta in data i appen som är bearbetad i förväg. Den tränade modellen laddas in för att kunna utföra prediktioner och testdata laddas in som färdiga sekvenser för att minimera beräkningstiden i appen.

Appen förutsätter att användaren är införstådd i vad som presenteras och hur graferna ska tolkas. Huvudsyftet med appen är att ge information om RUL (mätt som timmar kvar till predikterat fel). Användaren kan även kryssa i en ruta för att se prediktionen av sensordata jämfört med verkligt utfall. Dessa grafer ger mer en fingervisning (generalisering) kring eventuella mönster eller trender.

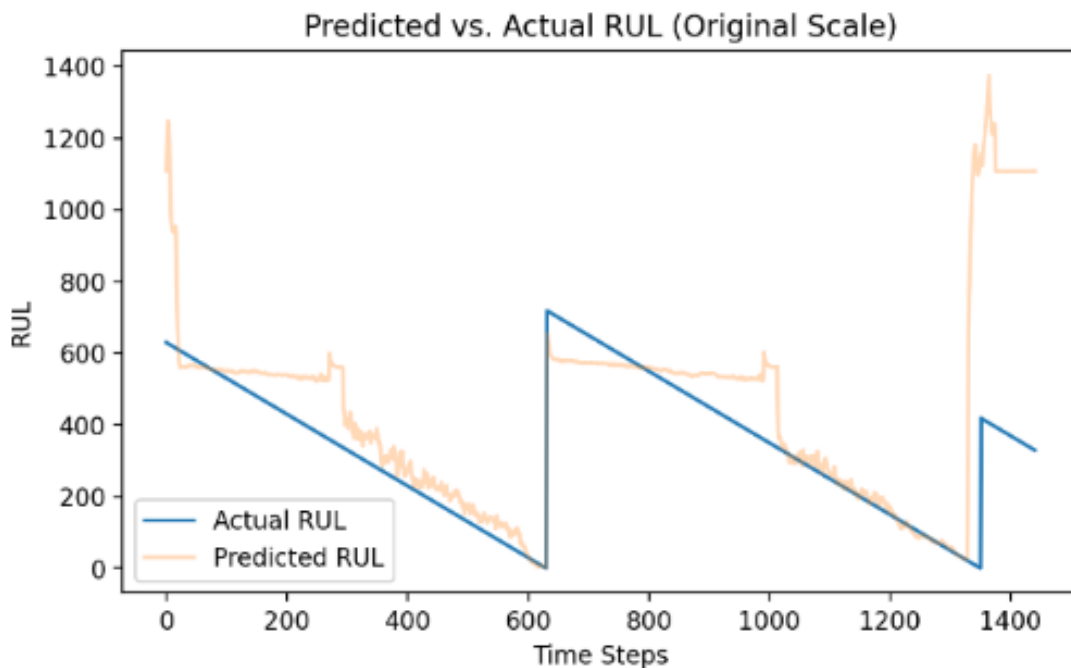


Figur 5. Exempel på bild från datorkameran som bearbetas och förbereds i Streamlit-applikationen innan prediktering.

4 Resultat och Diskussion

4.1 Modellerna


De modeller som valts ut har vissa brister men kan ändå ge en fingervisning. RUL-prediktionen ger en relativt god uppskattning av den tid som återstår innan nästa maskinfel väntas uppstå. Prediktionen är olika bra för de olika maskinerna så ett mätvärde blir inte riktigt rättvist. Det blir tydligare genom att visa resultatet i en graf i stället, se Figur 6 nedan. Generellt sett verkar det krävas en "invänjningstid" innan prediktionen kommer in i mönstret och närmar sig det verkliga värdet.



Figur 6. Predikerad RUL jämfört med verklig RUL, för maskin nr 17.

Beroende på träffsäkerheten kan åtgärder sättas in en viss tid innan felet uppstår, i stället för att byta ut maskindelar på regelbunden basis. Detta skulle kunna medföra färre byten av maskindelar vilket sparar både tid och pengar för produktionen.

Tittar vi på prediktionen av sensordata visar den mer en generalisering som följer eventuella mönster och trender, se Figur 7 nedan. Prediktionen ger oss inte något användbart resultat för vårt syfte.



Figur 7. Predikerade värden för "vibration" jämfört med verkliga värden, för maskin nr 17.

Med den data som finns tillgänglig är det inte lätt att skapa modeller som kan prediktera "rätt". Det kanske heller inte är möjligt. Det beror mycket på vilka parametrar vi har och hur bra de kan användas för att hitta de mönster som finns. Då detta dataset är fiktivt (syntetiskt) så är det heller inte säkert att det ens finns så mycket mönster att gå på. Men det har ändå gett en bra övning på att hantera tidsseriedata.

Hade det funnits data på kostnader avseende reparationer, stopp i produktion osv så hade även det kunnat bli en faktor för om det är värt att vänta med reparation eller inte.

4.2 Streamlit-applikationen

Applikationen används i detta fall för att visualisera prediktionerna så att de blir lite mer lättförståeliga. Vi kan använda Streamlit (eller liknande verktyg) som en "dashboard" för att förmedla olika resultat till olika användargrupper. Servicetekniker kan bland annat vara intresserade av när en viss maskin förväntas gå sönder så att de kan utföra underhåll i tid. Programutvecklare kan bland annat vara intresserade av om modellen fortfarande predikterar bra efter att datasetet uppdateras med nya data.

5 Slutsatser

Här besvaras frågeställningarna som ställdes i kapitel 1.2.

Klarar modellen av att prediktera RUL för maskinerna tillräckligt bra?

För vissa maskiner ger prediktionen ett bra resultat, framför allt när RUL närmar sig noll. Det gäller dock inte alla maskiner, så modellen är inte tillämpbar för alla. Men genom att studera vidare vad som gör att det fungerar bra eller mindre bra och om datasetet kan kompletteras med ytterligare data finns goda chanser att modellen går att förbättra.

Hur bra är modellen på att prediktera sensordata?

Modellen kan inte prediktera sensordata exakt utan ger en generalisering som följer mönster och trender. Därmed är prediktionen inte intressant för rapportens syfte. Hade det funnits data kopplat till varför sensorvärdena fluktuerar som de gör så hade det troligtvis gått att prediktera mer noggrant.

5.1 Vidare arbete

Modellerna kan alltid förbättras ytterligare, men begränsningar i data ger också begränsningar hos modellen. Det vore intressant att komplettera med mer data kopplat till sensorerna.

Streamlit-appen går att bygga vidare på och förbättra. Det vore det intressant att försöka göra beräkningsprocesserna mer effektiva så att appen blir mer användarvänlig. Även innehållet kan bli mer anpassat efter en särskild användargrupp.

6 Självutvärdering

1. Utmaningar du haft under arbetet samt hur du hanterat dem.

Den största utmaningen har varit att arbeta med modeller som är specialiserade för tidsseriedata, vilket var något nytt för alla i gruppen. Täta avstämningar och bra utbyte av idéer inom gruppen ledde till slut till bättre modeller.

2. Vilket betyg du anser att du skall ha och varför.

VG. Projektet känns väl genomarbetat och rapporten tar upp de viktigaste delarna.

3. Något du vill lyfta fram till Antonio?

Bra uppgift med grupparbete vilket ställer krav på samarbete och kommunikation.

Källförteckning

Géron, A. (2019). *Hands-on Machine Learning with Scikit-Learn, Keras & Tensorflow: Concepts, Tools and Techniques to Build Intelligent Systems (2nd ed.)*. Sebastopol: O'Reilly Media, Inc.

Schwaber, K. & Sutherland, J. (2020). *The Scrum Guide. The Definitive Guide to Scrum: The Rules of the Game*. Hämtat från <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>

Stratada. (2024). Hämtat från <https://www.stratada.com/remaining-useful-life-rul-prediction/>

Streamlit. (2024). Hämtat från <https://streamlit.io>

Wikipedia. (2024). Hämtat från https://en.wikipedia.org/wiki/Predictive_maintenance